「인터넷전자상거래연구」 제22권 제4호
2022년 8월, pp. 153~170
한국인터넷전자상거래학회
https://doi.org/10.37272/JIECR.2022.08.22.4.153

역사 맞춤형 정책 수립을 위한 지하철 역사의 유형화 및 특성 분석에 관한 연구: 서울 지하철 사례를 중심으로†

A Study on the Classification and Characterization Analysis Subway Station for the Customized Policies: Seoul Metropolitan Subway Cases

김 동 언* · 이 청 용** · 김 재 경***
Dongeon Kim · Qinglong Li · Jaekyeong Kim

··· Abstract ···

The Seoul metropolitan subway opened in 1974, and it became popular public transportation used by an average of 4.61 million passengers per day in 2021. Furthermore, by generating a vast amount of traffic data, it is showing value beyond public transportation. Developed countries utilize a combination of public transportation data and other types of data to efficiently develop public transportation operations and passenger-specific policies. On the other hand, despite various types of subway stations being added over time, the domestic study considers data of a single type (e.g., congestion, passenger, etc.). Such studies cannot effectively utilize traffic information and are challenging to utilize in various types of Seoul metropolitan subway. In this study, we aim to classify Seoul metropolitan subway from Line 1 to Line 9 by utilizing various data related to subway stations to suggest customized policies. The experiment results showed that the areas around the subway stations were categorized into three types: highly residential types, university·capital types, and transfer·commercial types. Our findings can provide appropriate policies for each type of subway station.

Key Words : Analysis, Clustering, Machine Learning, Seoul Metropolitan Subway.

논문 접수일: 2022년 08월 03일, 게재 확정일: 2022년 08월 24일
† 본 연구는 교육부 및 한국연구재단 4단계 두뇌한국21 사업(4단계 BK21 사업)과 2019학년도 경희대학교 연구비 지원에 의한 결과입니다(KHU-20191247). 지하철 관련 정보 제공에 협조해주신 서울교통공사에 감사를 드립니다.
* 경희대학교 빅데이터응용학과 석사과정, 주저자
** 경희대학교 빅데이터응용학과 박사과정, 공동저자
*** 경희대학교 경영대학&빅데이터응용학과 교수, 교신저자

Ⅰ. 서 론

서울 지하철의 하루 평균 이용 승객 수는 2021년 기준 약 461만 명으로 서울시민의 대표적인 대중교통 수단으로 자리매김하고 있으며, 현재는 이동 수단 이상의 가치를 나타내고 있다(이성희, 2022). 이처럼 지하철 이용이 활성화되면서 승·하차, 환승, 유동 인구 정보 등 다양한 유형의 교통정보 빅데이터가 축적되고 있다(박주석, 2018; 전병진·김희웅, 2017). 영국, 호주, 폴란드 등의 해외 국가에서는 수집한 교통정보 빅데이터를 효과적으로 활용하기 위해 다양한 유형의 빅데이터와 결합하여 지하철을 이용하는 승객 맞춤형 정책 수립을 위한 다양한 형태의 연구가 활발하게 진행되고 있다(황보현우, 2018). 예를 들어, 영국 런던에서는 와이파이 관련 데이터를 사용하여 지하철 역사와 차량 내부의 혼잡도를 분석하고 있으며, 이를 통해 지하철을 이용하는 승객에게 맞춤형 경로 안내를 제공하고 승객의 이동 동선 최적화에 활용하고 있다. 호주 시드니에서는 센서 관련 빅데이터를 바탕으로 지하철의 혼잡도를 분석하여 모바일 애플리케이션으로 제공하고 있다. 폴란드 바르샤바에서는 카메라 모니터링과 기계학습을 통해 지하철을 이용하는 승객의 수를 예측하고 있다. 교통정보 빅데이터를 바탕으로 지하철 이용 승객의 이동 패턴, 행동 특성 등 유용한 정보를 발견할 수 있고 이를 통해 수요 예측과 지역별 노선 개선 등에 활용할 수 있다(조수진 외, 2019). 이처럼 해외 지하철 관련 사례를 통해 교통정보 빅데이터의 활용도와 중요도가 점차 증가하고 있음을 확인할 수 있다(최봉·윤종진, 2018).

반면에 국내 지하철 관련 연구는 수요에 따라 꾸준히 지하철 노선의 수가 증가하고 있음에도 불구하고, 주로 단일 유형의 데이터를 기반으로 승·하차 인원 예측, 혼잡도 예측 등의 연구가 대부분이다. 민미경(2018)은 2008년부터 2017년까지 수집된 시간대별 지하철 승·하차 데이터를 기반으로 기계학습을 적용하여 서울시 지하철 역사의 승·하차 패턴을 분류하였다. 성진홍(2018)은 지하철 승·하차에 영향을 미치는 다양한 변수들을 다중 선형 회귀분석에 적용하여 서울 지하철 승·하차 인원을 예측하였다. 이처럼 대부분의 국내 연구는 최근 교통정보 빅데이터뿐만 아니라 다양한 유형의 빅데이터가 기하급수적으로 증가하고 있음에도 불구하고, 단일 유형의 데이터만을 이용하여 연구를 진행하였다. 다시 말해, 교통체계, 승객 이동 패턴 등과 같이 복합적이고 가치 있는 정보를 제공하는 교통정보 빅데이터와 다른 유형의 데이터를 결합하여 실험하는 연구는 상대적으로 부족한 실정이다. 따라서, 국내 지하철의 효율적인 운영을 위해 교통정보 빅데이터와 다양한 유형의 빅데이터를 활용하여 지하철 이용 특성을 고려한 맞춤형 정책 수립이 필요하다. 즉, 지하철이 활성화되면서 발생하는 문제점을 파악하고, 대중교통의 지속 가능한 발전을 도모하기 위해서는 교통정보 빅데이터와 다양한 유형의 빅데이터를 고려하여 효율적으로 지하철 역사를 유형화하고 이를 바탕으로 역사 유형별 맞춤형 정책이 마련되어야 한다. 이러한 배경하에 본 연구의 목적은 서울 지하철 교통정보 빅데이터와 지하철 역사 관련 공공 빅데이터를 바탕으로 지하철 역사를 유형화하고 유형별 특성을 비교하고 분석하고자 한다. 또한 분석 결과를 바탕으로 유형별 대중교통의 지속 가능한 발전을 위한 정책적 시사점을 제공

하고자 한다. 본 연구는 서울 지하철 역사 특성을 유형화하기 위해 지하철 특성을 나타내는 관련 변수를 선택하고, 이를 바탕으로 군집분석을 수행하여 지하철 역사별 특성을 추출하고 유형을 분류하였다. 본 연구의 공간적 범위는 서울 지하철의 1호선부터 9호선까지 203개의 역사를 분석에 사용하였다. 군집분석은 Python, 통계분석은 SPSS를 사용하였으며, 분석 결과에 대한 시각화는 Python과 QGIS를 사용하여 도출하였다.

본 연구의 나머지 구성은 다음과 같다. 제2장에서는 서울 지하철 교통정보 빅데이터와 군집분석 기반 특성 유형화 관련 연구를 설명한다. 제3장에서는 본 연구에서 제안하는 연구 방법에 관해 설명한다. 제4장에서는 실험 결과에 대해 구체적으로 설명하고, 제5장에서는 결과 토의, 시사점, 연구 한계점 및 추후 연구 계획을 기술한다.

II. 관련 연구

2.1 지하철 교통정보 빅데이터

해외 주요 선진국에서는 다양한 유형의 교통정보 빅데이터를 활용하여 맞춤형 교통 정책에 관한 연구를 활발하게 진행하고 있다. 반면에, 국내에서는 교통정보 빅데이터를 활용한 연구는 상대적으로 부족한 실정이다. 따라서, 본 연구에서는 국내 교통정보 빅데이터를 활용한 연구를 초점을 두고 선행 연구를 조사하였다. 김찬주·김영욱(2007)은 일반적인 건물과는 구조가 다른 지하철 역사 내 공간을 효율적으로 활용하기 위한 연구를 진행하였다. 먼저, 강남역을 이용하는 승객들의 이동 패턴을 분석하기 위한 관찰 조사와 강남역 전체 공간에 대한 공간구조 분석을 수행하였다. 실험 결과, 지하철 역사 내 승객의 이동 패턴이 역사 주변 지역의 특성에 영향을 받는 것을 확인하고 지하철 역사 내 공간을 효율적으로 활용하기 위한 계획을 제시하였다. 김진수(2016)는 지하철 혼잡도 예측을 통해 고객의 지하철 이용 편의성과 쾌적성을 극대화하기 위한 추천시스템 개발을 진행하였다. 2013년부터 2014년까지 지하철 1호선 통계자료와 계단, 엘리베이터 등의 지하철 역사 내 위치 정보를 수집한 후 다중 회귀분석을 통한 혼잡도 예측 및 추천시스템을 구축하였다. 실험 결과, 본 연구에서 제안한 추천시스템은 81% 정도의 정확도로 지하철 내 혼잡도를 예측하였으며, 제안한 추천시스템을 사용한 실험자 30명 중 23명이 만족하였다. 김용민 외(2017)는 역세권의 효율적인 개발과 관리방안을 제시하기 위한 연구를 진행하였다. 이를 위해 지하철 이용 승객 수가 많고 서울시의 주요 지점을 연결하고 있는 지하철 2호선의 2014년 10월 평일 5일간의 카드 사용 데이터를 수집하고 역세권 토지 정보를 활용하기 위해 2014년 역세권 토지이용 데이터를 수집하였다. 수집된 데이터를 바탕으로 지하철 이용 승객의 유·출입 패턴을 파악하여 유형화하고 유형에 따른 지하철 역사 이용 특성을 도출하였다. 이를 통해 향후 지하철 2호선 개발정책 및 계획수립에 기초적인 자료를 제공할 수 있을 것으로 기대하였다. 이상준·신성일(2020)은 지하철 이용 승객의 통행량 데이터를 기반으로 지하철 혼잡도를 개선하기 위한 관련 연구를 진행하였다. 이처럼 서울 지하철 교통정보 빅데이터를 활용한 선행 연구를 종합해보면 다음과 같은 세 가지 문제점

이 존재한다.

첫 번째, 유동 인구, 혼잡도 등과 같은 단일 유형의 데이터만을 이용하여 연구를 진행한다. 지하철 역사는 다양한 유형의 승객들이 이용하는 대중교통이며 지하철 역세권에 있는 상권들은 다양한 유형을 띄고 있으므로 단일 유형의 데이터만을 사용하는 경우 지하철 역사의 특성을 제대로 파악하는 것이 어렵다. 두 번째, 하루 혹은 5일 등 짧은 기간을 고려하고 있다. 대부분의 지하철 관련 연구는 이처럼 짧은 기간의 데이터를 수집하여 지하철 역사의 이동 패턴을 파악하거나 혼잡도를 개선하기 위한 연구를 진행하고 있다. 짧은 기간만을 고려하여 실험을 진행하면 표본의 수가 적어 지하철 역사 유형을 일반화하는 것이 어렵다. 세 번째, 특정 지하철 노선을 대상으로 한 연구를 진행하고 있다. 대부분의 연구가 1호선 혹은 2호선 등과 같이 지하철을 이용하는 승객 수가 많은 역사를 대상으로 연구를 진행하고 있다. 이용 승객이 많은 지하철 노선의 경우 기존 연구를 참고하여 맞춤형 정책을 시행할 수 있는 반면에, 5호선, 9호선 등과 같이 상대적으로 지하철 이용 승객이 적은 지하철 노선의 경우 승객 수가 많은 지하철 노선과 다른 특성을 나타낼 수 있기 때문에 이를 바탕으로 정책을 시행하는 것이 어렵다. 따라서, 본 연구에서는 혼잡도, 승·하차 인원, 환승역 지하철 인근 지리적 특성, 지하철 역사 특성 등과 같은 다양한 변수를 사용할 뿐만 아니라 서울 지하철 1호선부터 9호선까지 203개의 지하철 역사를 대상으로 2018년 2월부터 2019년 12월까지 총 23개월간의 데이터를 수집하여 지하철 역사 유형별 특성을 분류하고자 한다.

2.2 군집분석 기반 특성 유형화

기존의 여러 연구에서는 데이터의 다양한 특성을 효과적으로 분류하기 위해 군집분석을 적용하여 관련 특성을 유형화하는 연구를 제안하였다. 송민경·장훈(2010)은 수도권 내 지역을 도시 특성에 따라 지역 유형을 구분하고 특성을 파악하는 연구를 진행하였다. 실험을 위해, 인구밀도, 노령화지수 등의 사회문화적 요소와 공공기관 수, 단독 주택 구성비 등의 물리적 요소를 고려하여 다양한 유형의 데이터를 수집하였다. 수집된 데이터를 바탕으로 주성분 분석을 적용하여 공통 인자를 추출하고 군집분석을 수행하였다. 실험 결과, 수도권 도시를 총 5개의 군집으로 유형화하였으며, 이를 통해 향후 수도권 관리를 위한 계획과 정책 수립에 참고자료로 활용될 수 있는 시사점을 제시하였다. 여인권(2011)은 식중독 발생빈도에 기후가 어떠한 영향을 미치는지 확인하고자 실험을 진행하였다. 먼저, 1999년 1월 1일부터 2010년 6월 30일까지 전국 72개 관측소에서 측정된 국내 기상자료를 수집하였으며, 이를 바탕으로 계층적 군집분석을 수행하였다. 실험 결과, 기존 식중독 발생 예측 연구에서 사용한 산맥을 경계로 나눈 군집에서 다른 결과를 도출하는 것을 확인하였으며, 이를 통해 추후 기상자료를 바탕으로 이루어지는 연구에 기초자료를 제공할 것을 기대하였다. 이준호·박광호(2012)는 중소기업을 대상으로 온라인 마케팅 지원 프로그램을 구축하기 위한 연구를 진행하였다. 먼저, 572개의 기업을 대상으로 2011년 12월 12일부터 2011년 12월 27일까지 설문조사를 진행하여 수집한 367개 기업의 설문조사 데이터를 바탕으로 군집분석과 분산분석을 수행

하였다. 실험 결과, 중소기업을 신생기업, 성장기업, 성숙기업 등으로 분류하였으며, 각 군집에 적합한 기업 세분화 전략을 제시하였다. 이다예·이희연(2016)은 수도권 근교 농촌의 다양한 특성을 고려하여 맞춤형 계획 및 정책을 제시하기 위한 연구를 진행하였다. 수도권에 속한 행정구역상 152개의 근교 농촌과 이와 관련된 데이터를 통계청, 인터뷰 그리고 설문조사 등 다양한 방법으로 수집한 후 군집분석을 수행하였다. 실험 결과, 수도권 근교 농촌을 전원·농촌관광형, 침상도시형, 일반농촌형, 농·공 혼재형 등 네 가지 유형으로 분류하였으며, 유형별 특성에 맞는 정책이 필요하다는 결론을 도출하였다. Mathivanan et al. (2019)는 k-평균 군집분석을 사용하여 데이터의 패턴을 파악하고 선별된 제품을 효율적으로 그룹화하는 연구를 진행하였다. 먼저, 말레이시아 통계청에서 온라인 쇼핑몰의 제품 정보를 수집하고, k-평균 군집분석을 수행하였다. 실험 결과, 온라인 쇼핑몰의 제품을 비슷한 특성을 가지는 3개의 그룹으로 군집화하고, 이를 바탕으로 추천시스템을 구축할 수 있다는 것을 확인하였다, Zarikas et al. (2020)은 COVID-19의 의학적, 경제적, 사회적 영향을 탐구하기 위해 군집분석을 수행하여 다양한 문제에 대한 해결책을 찾고 전략을 제안하기 위한 연구를 진행하였다. 먼저, 존스 홉킨스 대학에서 제공하는 2020년 1월 22일부터 2020년 4월 4일까지의 COVID-19 데이터를 수집하였다. 수집된 데이터를 바탕으로 계층적 군집분석을 수행하였으며, 실험 결과 COVID-19 확산 및 결과가 다른 국가들을 객관적으로 구분하였다. 이를 통해 의료, 경제, 정치 등의 영향을 파악하여 정책 수립에 시사점을 제공할 것으로 기대하였다.

이처럼 전자상거래, 마케팅, 도시정책, 농촌 등 다양한 분야에서 데이터의 특성을 유형화하기 위해 군집분석을 활용한 연구가 진행되고 있다. 그러나 교통정보 빅데이터를 활용한 연구에서는 군집분석이 데이터를 유형화하는 것에 있어 성능이 우수하지만, 사례분석, 다중회귀분석 등을 통해 실험을 진행하였다. 이와 같은 분석 방법은 혼잡도, 이용 승객 예측 등의 연구에는 우수한 성능을 발휘할 수 있으나, 승객의 이동 패턴, 혼잡도 등 여러 특성을 효과적으로 유형화하는 것은 상대적으로 어렵다. 따라서, 본 연구에서는 군집분석을 통해 지하철 역사에 영향을 미치는 다양한 교통정보 빅데이터를 고려하여 여러 유형으로 분류하고 각 유형의 특성을 파악하고자 한다.

Ⅲ. 연구방법

3.1 데이터 수집 및 전처리

본 연구의 목적은 서울 지하철 역사의 특성을 유형화하고 유형별 특성을 비교하고 분석하는 것이다. 이를 위해 지하철 역사에 영향을 미치는 여러 변수를 통해 지하철 역사를 유형화하고, 각 유형의 특성을 세부적으로 파악하여야 한다. 따라서, 지하철 역사 특성을 효과적으로 반영할 수 있는 관련 변수를 선택하는 것이 중요하다. 본 연구에서는 효과적인 분석을 위해 지하철 역사 요소와 토지 요소를 기반으로 지하철 역사 특성을 반영할 수 있는 다양한 변수를 활용하였다. 또한, 일부 기간 혹은 특정 노선만을 고려하여 실험을 진행해 일반화가 어려운 기존 선행 연구의 한계를 개선하기 위해 2018년 2월 9일부터 2019년 12

월 31일까지 23개월간 수집된 서울 지하철 1호선부터 9호선까지 203개의 지하철 역사 데이터를 활용하여 실험을 진행하였다. <표 1>는 지하철 역사의 다양하고 이질적인 특성을 나타낼 수 있는 변수를 역사 요소와 토지 요소로 구분하여 각 요소에 대한 변수별로 나타내고 있다.

다양한 변수 중 지하철 역사 요소 내 대학교, 버스 정류장 등과 지하철 토지 요소 내 주거 면적, 상업업무 면적, 공업 면적 비율 등의 변수는 지하철 역사 반경을 설정해야 한다. 기존 대부분의 연구에서 지하철 역사를 분석하기 위해 역사 주변 반경을 500m로 설정하고 있으며, 본 연구에서도 마찬가지로 지하철 역사 주변 반경을 500m로 설정하고 이를 기준으로 자료를 수집하였다(김용민 외, 2017; 성현곤 외, 2006; 손동욱·김진, 2010). 본 연구에서 수집한 데이터에서 대학교, 버스 정류장과 같은 데이터의 경우 위·경도 좌표에 대한 데이터가 아닌 주소로 구성되어 있어 군집분석을 수행하기 위한 데이터로 사용하기 어렵다. 따라서, 주소를 위·경도 좌표로 변환하는 데이터 전처리 과정을 수행하였다. 추가로 변환된 대학교의 위·경도 좌표를 군집분석의 변수로 사용하기 위해 지하철 역사 반경 500m 내에 위치하는 대학교, 버스 정류장의 수로 변환하였다. 혼잡도와 주거 면적 비율, 상업업무 면적 비율 등의 데이터는 비율로 구성되어 있으나 승·하차 인원, 지하철 역사 면적과 같은 데이터의 경우 인원수 혹은 면적으로 구성되어 있다. 이처럼 단위가 다른 데이터를 사용하여 군집화를 수행하는 경우 단위가 큰 데이터에 편향(Bias)되어 데이터의 군집분석의 성능이 저하될 수 있다. 따라서 본 연구에서는 효과적인 분석을 위해 데이터의 범위를 0과 1 사이의 값으로 정규화(Normalization)하는 작업을 수행하였다(Bharati et al., 2020).

3.2.1 계층적 군집분석

계층적 군집분석은 와드연결법(Ward Linkage Method)을 적용하였으며, 이는 군집 내 제곱의 합 증분과 군집 간 제곱의 합을 모

<표 1> 지하철 역사 유형별 군집화를 위한 변수

구분	변수	변수 설명	활용 데이터
역사 요소	혼잡도	(탑승 인원/표준 탑승 인원) * 100	공공데이터포털
	승차 인원	시간대 별 승차 인원	공공데이터포털
	하차 인원	시간대 별 하차 인원	공공데이터포털
	환승역	지하철역 환승 가능 여부	서울교통공사
	지하철 역사 면적	지하철 역사 면적	서울교통공사
	대학교	지하철 역사 반경 500m 내 대학교 수	공공데이터포털
	버스 정류장	지하철 역사 반경 500m 내 버스 정류장 수	공공데이터포털
토지 요소	주거면적 비율	지하철 역사 반경 500m 내 전체 면적 대비 주거용 토지면적 비율	한국부동산원
	상업업무면적 비율	지하철 역사 반경 500m 내 전체 면적 대비 상업용 토지면적 비율	한국부동산원
	공업면적비율	지하철 역사 반경 500m 내 전체 면적 대비 공업용 토지면적 비율	한국부동산원

두 고려하고 있다(Murtagh & Contreras, 2012). 이 방법은 각 군집의 편차제곱합(ESS: Error Sum of Squares)의 증가를 최소화하는 방식으로 유사한 대상을 결합하면서 군집을 형성하며, 군집 A와 B 간 거리는 아래와 같이 나타낼 수 있다(Roux, 2018).

$$E_A = \sum_{j=1}^{n_A}\sum_{k=1}^{p}(X_{Ajk} - \overline{X}_{AK})^2 \qquad (1)$$

$$E_B = \sum_{j=1}^{n_B}\sum_{k=1}^{p}(X_{Bjk} - \overline{X}_{BK})^2 \qquad (2)$$

여기서 $\overline{X}_{AK}$와 $\overline{X}_{BK}$는 각 군집의 평균 관측값을 나타내고 있다. 이 방법은 각 군집의 모든 변수에 대한 평균값을 계산하고, 해당 평균값과 군집에 포함된 개체 간의 유클리드 거리 제곱을 계산하여 합계를 계산하며, 이후 단계별로 해당 값의 증가를 최소화하는 방식으로 군집을 형성한다.

3.2.2 비계층적 군집분석

이에 따라 본 연구는 앞서 도출한 군집 수를 바탕으로 비계층적 군집분석에서 주로 사용되는 k-평균 군집분석을 적용하여 분석을 수행하였다(Roux, 2018; Shukla & Naganna, 2014). 이 방법은 개별 사건과 k개 중심점과의 거리를 계산하여 가장 가까운 거리를 나타내는 군집에 개별 사건을 할당하는 방식으로 군집을 형성한다. 초기에 임의로 선택된 k개 사례의 값이 최초의 k개의 중심점 역할을 수행한다. 최초의 중심점이 정해지면 개별 사례 간의 거리를 계산하여 가장 가까운 중심점이 속한 군집에 할당하여 새로운 중심점을 계산한다. 이러한 방식으로 군집 평균에 대한 값이 변화가 없거나 사전에 정한 반복 횟수에 도달할 때까지 이를 반복하여 군집을 형성한다. 계층적 군집분석과 다르게 k-평균 군집분석은 군집 수를 미리 결정하고 분석을 수행해야 하므로, 사전에 최적의 군집 수를 정하는 것이 매우 중요하다. 군집 수가 정해지면 군집 내 행렬 W와 군집 간 행렬 B가 구축되며, 이를 바탕으로 최종적으로 전체 행렬 T가 형성된다.

$$W = \sum_{i=1}^{g}\sum_{j=1}^{N_i}(X_{ij} - \overline{X}_i)(X_{ij} - \overline{X}_i)' \qquad (3)$$

$$B = \sum_{i=1}^{g} N_i(\overline{X}_i - \overline{X})(\overline{X}_i - \overline{X})' \qquad (4)$$

$$\begin{aligned} T &= \sum_{i=1}^{g}\sum_{j=1}^{N_i}(X_{ij} - \overline{X})(\overline{X}_{ij} - \overline{X})' \\ &= W + B \end{aligned} \qquad (5)$$

여기서 X_{ij}는 i번째 군집에 속한 j번째 개체 값을 나타내는 p차원 벡터값을 의미한다. $\overline{X}_i$와 $\overline{X}$는 각각 i번째 군집의 p차원 벡터값과 전체 데이터의 p차원 벡터값을 의미한다. g는 군집의 수를 나타내고, N_i는 i번째 군집의 관측 개체 수를 의미한다.

k-평균 군집분석에서 최적의 군집을 형성하는 기준은 군집 내 행렬보다 군집 간 행렬의 흩어짐이 커야 하며, 다시 말해 다음과 같이 $tr(W)$를 최소화하는 방식으로 군집을 형성하게 된다(Xu & Tian, 2015; Xu & Wunsch, 2005).

$$\begin{aligned} tr(W) &= \sum_{i=1}^{g} tr(W_i) \\ &= \sum_{i=1}^{g}\sum_{j=1}^{N_i}(X_{ij} - \overline{X}_i)'(X_{ij} - \overline{X}_i) \end{aligned} \qquad (6)$$

본 연구에서는 지하철 역사 특성을 효과적으로 분류하기 위해 먼저 계층적 군집분석을 수행하여 최적의 군집 수를 도출하고 이를

k-평균 군집분석의 초기 군집 수로 설정하고 실험을 진행하였다.

Ⅳ. 실험 결과

본 연구에서는 지하철 역사 특성을 유형화하기 위해 다음과 같은 방법으로 실험을 진행하였다. 먼저, 공공데이터포털[1], 서울교통공사[2], 한국부동산원[3] 등에서 수집한 데이터를 군집분석에 활용하기 위해 전처리 작업을 수행하였다. 다음으로, 전처리가 완료된 데이터를 바탕으로 계층적 군집분석을 수행하여 최적의 군집 수를 도출하였다. 마지막으로, 이전 단계의 실험 결과를 바탕으로 비계층적 군집분석을 수행하여 지하철 역사 특성을 유형화하였으며 구체적인 실험 결과는 다음과 같다.

<그림 1>에서 (a), (b), (c), (d)는 각각 평균연결법, 완전연결법, 단일연결법, 와드연결법에 대한 덴드로그램(Dendrogram)을 나타내고 있다. 평균연결법, 단일연결법 그리고 완전연결법의 경우 군집 내 지하철 역사 수가 같은 군집에 90% 이상의 지하철 역사가 속해 있어 특정 군집에 편향된 결과를 보여주고 있다. 반면에, 와드연결법의 경우 군집 내 지하철 역사 수가 균등하게 분포된 것을 확인할 수 있다.

와드연결법을 제외한 평균연결법, 완전연결법, 단일연결법 등과 같은 계층적 군집분석은 두 군집 간의 거리를 계산하여 군집을 선정하는 방식을 사용하기 때문에 데이터에 이상치(Outlier)가 존재하는 경우 군집분석의 성능이 저하될 수 있다. 반면에, 와드연결법은 군

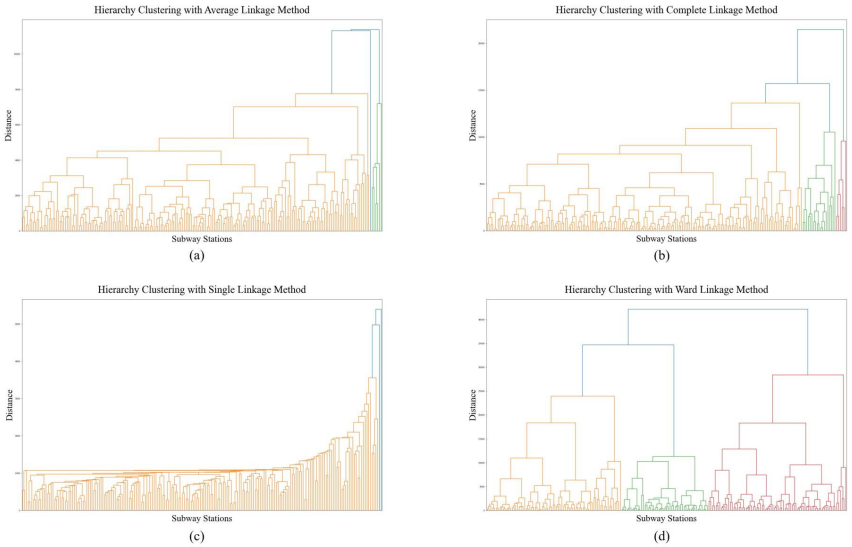

<그림 1> 계층적 군집분석 덴드로그램(Dendrogram)

1) https://www.data.go.kr/
2) http://www.seoulmetro.co.kr/kr/board.do?menuIdx=551
3) https://www.reb.or.kr/reb/na/ntt/selectNttList.do?mi=10251&bbsId=1268

집 간의 거리를 기반으로 군집을 선정하는 방식이 아닌, 군집 내 편차제곱합을 통해 군집을 선정하는 방식을 사용하고 있다. 이와 같은 방식은 군집 간의 거리를 계산하는 과정에서 상대적으로 이상치에 덜 민감하다는 장점이 있다. 따라서, 본 연구에서는 상대적으로 이상치에 민감하지 않은 와드연결법을 사용하여 최적의 군집 수를 도출하였다. 적절한 군집의 수를 선정하는 기준은 군집 내 응집력이 높고, 군집 간 이질성이 큰 경우의 군집 수를 적절한 군집의 수로 판단한다. 군집분석에서 응집력은 군집 내 데이터가 같은 특성으로 구성된 정도를 의미하고, 이질성은 서로 다른 군집에 속한 데이터가 다른 특성을 가지는 정도를 의미한다. 와드연결법의 경우 군집의 수가 3일 때 군집 내 응집력이 높고, 군집 간 이질성이 크기 때문에 이를 적절한 군집의 수로 설정한 후 비계층적 군집분석을 수행하였다.

4.2 비계층적 군집분석 결과

앞서 수행한 계층적 군집분석의 실험 결과 군집의 수가 3인 경우 가장 적절하게 분류가 되었다. 이전 실험의 신뢰성을 높이기 위해 추가적으로 비계층적 군집분석을 적용하여 엘보우 기법(Elbow Method)를 통해 적절한 군집의 수를 도출하고 계층적 군집분석의 실험 결과와 동일한 결과가 도출되는지 확인하고자 한다. 엘보우 기법은 비계층적 군집분석에서 군집의 수를 결정하기 위해 주로 사용되는 기법의 하나며, 군집 내 포함된 데이터들이 퍼져 있는 정도를 나타내는 관성(Inertia)을 바탕으로 적절한 군집의 수를 선정하는 기법이다(Syakur et al., 2018). 일반적으로 관성이 급격하게 떨어지거나 관성의 변화량이 줄어드는 기점의 군집 수를 적절한 군집의 수로 판단하여 선정한다(Syakur et al., 2018). 본 연구에서는 비계층적 군집분석 중 널리 사용되는 k-평균 군집분석을 사용하였으며(Xu

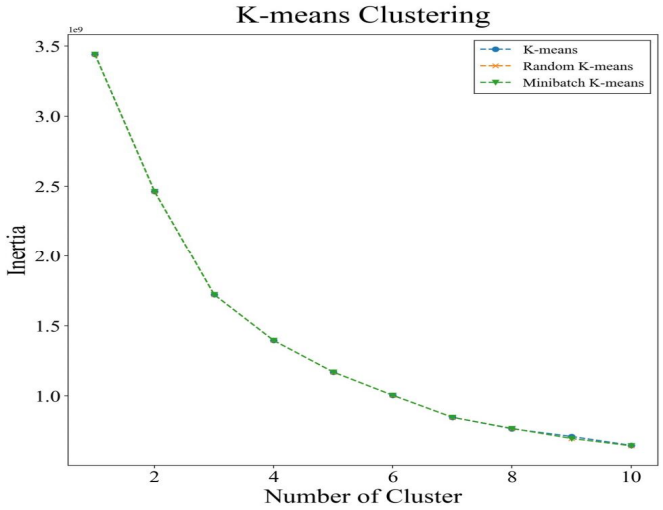

<그림 2> k-평균 군집분석의 실험 결과

& Wunsch, 2005), 실험 결과는 <그림 2>와 같다.

실험 결과, 군집의 수가 2에서 3으로 변화하는 시점에 관성이 급격하게 떨어지는 것을 확인할 수 있으며, 군집의 수가 3에서 4로 변화하는 시점이 이전 시점에 비해서 관성의 변화량이 감소한 것을 확인할 수 있다. 따라서, 군집의 수가 3인 경우를 적절한 군집의 수로 지정할 수 있다. 이전 단계에서 진행한 계층적 군집분석의 실험 결과와 마찬가지로. k-평균 군집분석의 실험 결과에서도 적절한 군집의 수가 3인 것을 확인할 수 있다. 따라서, 본 연구에서는 앞서 수행한 실험 결과를 바탕으로 군집의 수를 3으로 설정하고 실험을 진행하였다. 실험 결과, 각 군집에 대한 평균과 분산은 <표 2>와 같다. 실험 결과에 따르면, 군집 1의 경우 다른 군집에 비해 상대적으로 출근 시간대 및 퇴근 시간대의 유동 인구와 혼잡도가 낮은 수치를 보이고 있으나, 지하철 역사 반경 500m 내 주거 면적 비율이 가장 높은 것을 확인할 수 있다. 이를 통해 군집 1은 주거밀집형으로 구분 지을 수 있다. 군집 2의 경우 대체로 출근 시간대에 비해 퇴근 시간대의 유동 인구가 많은 것을 확인할 수 있으며, 전체적으로 높은 혼잡도 비율을 나타내고 있다. 또한, 지하철 역사 반경 500m 내 대학교 비율이 28%로 다른 군집에 비해 월등히 높은 것을 확인할 수 있다. 이를 통해 군집 2는 대학·도심형으로 구분 지을 수 있다. 마지막으로, 군집 3의 경우 출근 시간대와 퇴근 시간대의 유동 인구가 다른 군집에 비해 많은 것을 확인할 수 있고 군집 내 지하철역의 83%가 환승역인 것을 확인할 수 있다. 또한, 지하철 역사 반경 500m 내 상업업무 면적 비율이 47%로 가장 높은 비율을 나타내고 있다. 이를 통해 군집 2는 경유·상업형으로 구분 지을 수 있다.

분석 결과를 바탕으로 요약하면, 각 군집의 특성과 이에 포함되는 지하철 역사는 <표 3>과 같다. 또한 각 군집의 특성을 바탕으로

<표 2> 지하철 역사 군집 별 기초 통계량

변수	군집 1		군집 2		군집 3	
	평균	표준편차	평균	표준편차	평균	표준편차
출근 시간대 혼잡도(%)	24.52	17.06	41.71	20.95	**44.65**	17.57
퇴근 시간대 혼잡도(%)	29.68	20.16	**65.23**	22.11	54.56	16.50
출근 시간대 유동 인구(명)	1645.73	1071.11	3773.03	2013.56	**3977.70**	1665.11
퇴근 시간대 유동 인구(명)	1686.65	1101.48	**5128.81**	2161.58	4398.64	1842.49
환승역(수)	0.20	0.40	0.02	0.12	**0.83**	0.38
지하철 역사 면적(m^3)	7132.49	2165.71	7163.28	2236.40	**9819.35**	3531.15
대학교(수)	0.05	0.21	**0.28**	0.45	0.10	0.30
정류소(수)	5.68	3.31	5.02	2.29	**10.06**	5.05
주거 면적 비율(%)	**0.65**	0.19	0.59	0.20	0.36	0.23
상업업무 면적 비율(%)	0.14	0.10	0.23	0.16	**0.47**	0.29
공업 면적 비율(%)	0.00	0.01	0.01	0.04	**0.03**	0.14
해당 지하철 역사 수	87		64		52	
군집명	주거밀집형		대학·도심형		경유·상업형	

<표 3> 지하철 역사 군집별 특성 비교

구분	군집1(주거밀집형)	군집2(대학·도심형)	군집3(경유·상업형)
특성	다른 군집에 비해 출근 시간대와 퇴근 시간대의 유동 인구가 적지만, 주거 면적 비율은 가장 높음.	지하철 역사의 28%가 반경 500m 내 대학이 존재하며, 환승역으로 구성되어 있지 않으나 유동 인구가 상대적으로 많음.	출근 시간대와 퇴근 시간대 모두 혼잡하고, 군집 내 지하철역의 대부분이 환승역으로 구성되어 있고, 상업 면적 비율이 가장 높음.
지하철 역명	강동구청, 개화산, 경찰병원, 고덕, 고려대, 공릉, 광흥창, 구산, 구파발, 굽은다리, 길동, 까치산, 남한산성입구, 노원, 녹사평, 단대오거리, 당고개, 대청, 대치, 대흥, 도곡, 도봉산, 독립문, 독바위, 돌곶이, 디지털미디어시티, 마들, 마포구청, 망원, 매봉, 먹골, 명일, 모란, 목동, 몽촌토성, 무악재, 발산, 방화, 버티고개, 보라매, 보문, 봉화산, 불광, 산성, 상계, 상봉, 상수, 상월곡, 상일동, 새절, 송정, 수락산, 수서, 수진, 신금호, 신정, 신풍, 신흥, 안암, 암사, 애오개, 역촌, 연신내, 오금, 우장산, 월곡, 응암, 이촌, 이태원, 일원, 장암, 제기동, 중계, 중화, 증산, 창동, 창신, 천왕, 천호, 청구, 하계, 학여울, 한강진, 행당, 화곡, 화랑대, 효창공원앞	강변, 경복궁, 광나루, 광명사거리, 구로디지털단지, 구의, 금호, 길음, 낙성대, 남구로, 남부터미널, 남태령, 내방, 녹번, 논현, 답십리, 동대입구, 뚝섬, 뚝섬유원지, 마장, 마포, 면목, 명동, 문정, 미아, 반포, 방배, 봉천, 사가정, 상왕십리, 서대문, 서울대입구, 서초, 성신여대입구, 송파, 수유, 숙대입구, 숭실대입구, 신대방, 신대방삼거리, 신림, 신사, 잠실새내, 신촌, 쌍문, 아차산, 아현, 안국, 압구정, 어린이대공원, 여의나루, 역삼, 오목교, 용마산, 이대, 잠실나루, 잠원, 장지, 중곡, 청담, 학동, 한성대입구, 혜화, 홍제	가락시장, 가산디지털단지, 강남, 강남구청, 강동, 건대입구, 고속터미널, 광화문, 교대, 군자, 당산, 대림, 동대문, 동대문역사문화공원, 동묘앞, 동작, 문래, 복정, 사당, 삼각지, 삼성, 석계, 석촌, 선릉, 성수, 시청, 신길, 신당, 신도림, 신설동, 신용산, 약수, 양재, 여의도, 영등포구청, 영등포시장, 온수, 왕십리, 을지로3가, 을지로4가, 을지로입구, 잠실, 종각, 종로3가, 종로5가, 종합운동장, 충무로, 충정로, 태릉입구, 합정, 홍대입구, 회현

지하철 역사를 지도에 반영하면 <그림 3>, <그림 4> 및 <그림 5>와 같다. <그림 3>, <그림 4>, <그림 5>는 각각 군집 1(주거밀집형), 군집 2(대학·도심형), 군집 3(경유·상업형)에 포함되는 지하철 역사를 나타내고 있다. 군집 1의 경우 지하철역 대부분이 은평구, 노원구, 강동구, 도봉구, 강북구 등의 행정구역에 포함되어 있다. 해당 행정구역은 대부분 외곽 지역에 있으며, 주거를 목적으로 하는 행정구역인 것을 확인할 수 있다. 군집 2의 경우 관악구, 성북구, 서대문구 등 대학교가 많은 지역, 혹은 강남구, 구로구 등 상업시설이 많은 지역에 전체적으로 고르게 분포된 것을 확인할 수 있다. 군집 3의 경우 영등포구, 중구, 종로구에 밀집된 것을 확인할 수 있다. 대부분의 지하철 역사가 환승역으로 구

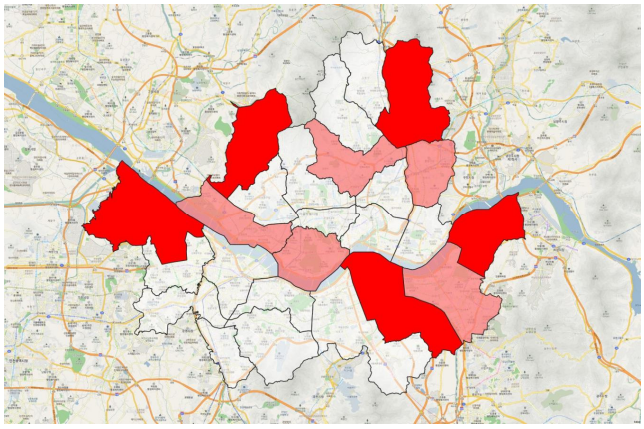

<그림 3> 군집 1(주거밀집형)

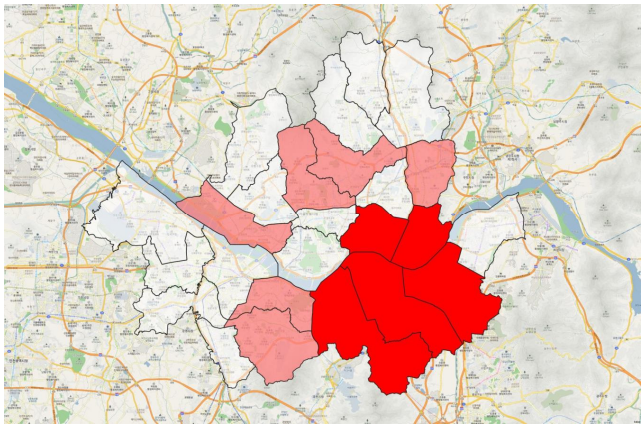

<그림 4> 군집 2(대학·도심형)

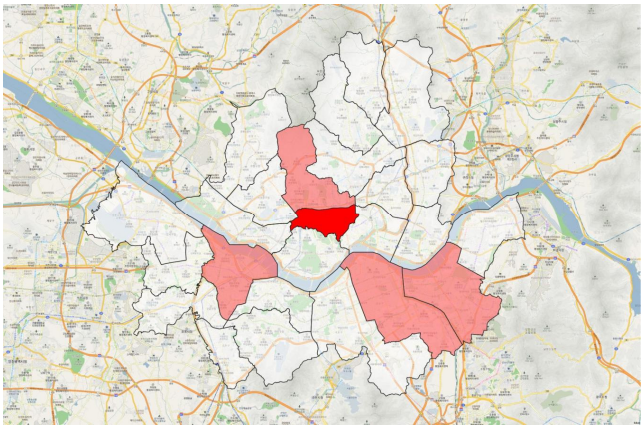

<그림 5> 군집 3(경유·상업형)

성되어 있을 뿐만 아니라 전체적인 유동 인구가 많은 역이 해당 군집에 포함된 것을 확인할 수 있다.

실험 결과를 요약하면 다음과 같다. 군집 1(주거밀집형)은 녹사평, 까치산, 연신내, 응암 등 지하철 역사를 포함하고 있다. 군집 1의 주요 특성을 파악해보면, 유동 인구는 적지만 지하철 역사 반경 500m 내 주거 면적 비율이 가장 높고 대부분의 지하철 역사가 외곽 지역에 있는 것을 확인할 수 있다.

노원구, 도봉구, 은평구 등 상대적으로 외곽 지역에 위치하는 경우 강남구, 서초구 등의 도심 지역에 비해 부동산 가격이 저렴하여 주거 지역이 밀집되어 있다. 급속한 경제 성장으로 인해 노원구, 도봉구, 은평구 등 상대적으로 외곽 지역에 있으며 부동산 가격이 저렴한 지역은 주거 지역으로 구분되고, 강남구, 서초구 등의 도심에 있는 지역은 중심지로 구분되었다(신임호, 2012; 임상빈·김병남, 2021). 한상욱 외. (2015)의 연구를 통해 외곽에 위치한 주거 지역에서 강남, 종로, 여의도 등의 업무 지역으로 지하철을 이용하여 통근하는 것을 확인하였으며, 기존 선행 연구의 결과와 본 연구의 실험 결과를 바탕으로 다음과 같은 맞춤형 정책을 제안할 수 있다. 외곽 지역에서 강남, 종로 등의 업무 지역으로 통근하는 경우 지하철 내에서 머무르는 시간이 많이 소요된다. 이 같은 경우 지하철 역사 내 공간을 활용하는 것보다 지하철 내 광고를 시행하는 경우 효율적으로 광고를 시행할 수 있다. 또한, 출퇴근을 위주로 이용되는 지하철 역사의 경우 출·퇴근과 같은 특정 시간대에 유동 인구가 집중되는 현상이 발생한다. 이를 고려한 혼잡도 개선 연구 혹은 특정 목적지에 맞는 최적의 지하철 열차 칸을 추천하는 시스템 등의 정책을 제안할 수 있다. 군집 2(대학·도심형)는 압구정, 역삼, 청담 등의 도심 지역뿐만 아니라 낙성대, 동대입구, 숙대입구 등의 대학가에 분포하고 있는 것을 확인할 수 있다. 또한, 지하철 역사는 대부분 환승역으로 구성되어 있지 않음에도 불구하고 유동 인구가 많은 것을 확인할 수 있다. 이는 해당 역사를 환승역으로 사용하는 것이 아니라 실질적으로 이용하는 승객이 많다는 것을 의미한다. 이창효·이승일(2010)은 범죄, 교통 등의 안정성과 대중교통, 편의시설 등 편리성과 같은 세부 영역으로 1인 가구 밀집 지역의 주거환경을 평가하고 그 특성을 분석하였다. 실험 결과, 도심 및 강남의 업무중심지와 대학교 주변 지역에 1인 가구가 밀집되어 있다는 것을 확인하였으며, 신림동 인근에는 남성 거주자가 집중되어 있고, 강남 지역에는 여성 거주자가 집중되어 있다는 것을 확인하였다. 기존 선행 연구의 결과와 본 연구에서 도출한 실험 결과를 바탕으로 다음과 같은 맞춤형 정책을 제안할 수 있다. 먼저, 대학교 주변 지역에 거주하고 있는 1인 가구의 경우 대학생을 대상으로 한 지하철 광고를 도입할 수 있다. 최근 정보통신 기술의 발전으로 다양한 유형의 광고를 진행할 수 있다. 따라서, 다양한 전자 매체를 통해 대학생이 선호하는 제품을 광고하여 광고 효과를 극대화할 수 있다. 또한, 업무중심지에 거주하는 1인 가구를 위한 지하철 역사 내 밀키트 판매점, 편의시설 등의 업종을 입점하여 지하철 역사 매출에 기여할 수 있다. 마지막으로, 군집 3(경유·상업형)의 경우 유동 인구가 많으나 대부분의 지하철 역사가 합정, 고속터미널, 을지로 3가 등의 환승역으로 구성되어 있으며, 다른 군집에 비해 지하철 역사 반경 500m 내 상업 면적 비율이

가장 높은 것을 확인하였다. 최근 저출산, 고령화 문제로 인한 지하철의 운임 수익이 감소하고 있으며, 만성 적자에 시달리는 운영기관의 새로운 부대 수익 창출과 효율적인 지하철 역사 내 공간 활용이 필요하다(이근영 외, 2014; 장재민 외, 2016). 또한, 지하철 이용 승객의 특성을 고려하지 않은 지하철 광고로 인해 광고의 효과가 저하되고, 심지어 승객의 불쾌함을 초래할 수 있기 때문에 승객 맞춤형 광고의 필요성이 제기되고 있다(문서현, 2017; 송치영 외, 2018; 이종민·한광석, 2007). 본 연구에서 도출한 군집 3의 주요 특성을 바탕으로 유동 인구가 상대적으로 많은 군집 3의 지하철 역사를 바탕으로 해당 군집에 포함된 지하철 역사를 이용하는 승객의 선호를 고려하여 맞춤형 광고 추천시스템을 도입할 수 있다. 추가로 승객의 연령 정보나 해당 행정구역의 인구통계학적 특성을 나타내는 데이터를 확보하여 다양한 지하철 맞춤형 광고 정책을 도입할 수 있다.

V. 결 론

본 연구는 서울의 대표적인 대중교통인 지하철 역사를 유형화하고, 유형별 특성을 비교 및 분석함으로써 대중교통의 지속 가능한 발전을 위한 이론적 및 실무적 시사점을 도출하는 데 목적을 두고 있다. 이와 같은 연구 목적을 달성하기 위해 지하철 역사의 특성을 효과적으로 나타내는 다양한 변수들을 선정하고 이를 바탕으로 군집분석을 수행하였다. 분석 결과, 서울 지하철 역사 유형은 주거밀집형, 대학·도심형, 경유·상업형 등 세 가지 유형으로 분류되었다. 주거밀집형은 다른 유형에 비해 출·퇴근 시간대에 유동 인구가 상대적으로 적으나 주거 면적이 높은 특성을 보여주고 있으며 주로 외곽 지역에 분포된 특성을 나타낸다. 디지털미디어시티, 당고개 등의 지하철 역사와 같이 외곽 지역에 있으며 주거 비율이 상대적으로 높은 역사가 여기에 해당한다. 대학·도심형은 지하철 역사 근처에 대학, 시장, 공원 등이 있으며 환승역이 포함되지 않지만, 유동 인구가 많은 특성이 있다. 대표적으로 역사 근처에 대학이 있는 서울대입구, 신촌이 등이 포함되고, 공원 환경이 좋은 여의나루가 여기에 포함된다. 경유·상업형은 지하철 역사 근처에 상업시설이 많고 지하철 역사가 환승역으로 구성되어 있으므로 출·퇴근 시간대에 혼잡한 특성을 나타내고 있다. 상업시설이 많은 가산디지털단지, 여의도 등의 지하철 역사와 환승 시설을 보유하고 있는 사당, 잠실 등의 지하철 역사가 여기에 포함된다.

본 연구는 다음과 같은 이론적 시사점을 제공하고 있다. 첫째, 기존 지하철 관련 연구에서는 주로 지하철 관련 단일 유형의 데이터를 사용하였다. 지하철 이용 승객들은 출근, 등교, 쇼핑 등 다양한 이동 목적을 바탕으로 지하철을 이용하고 있으므로 지하철 관련 데이터(예: 승·하차 인원수, 혼잡도 등) 외에 추가로 지하철 역사 특성을 반영하는 데이터를 고려해야 한다. 본 연구에서는 이러한 문제점을 개선하기 위해 지하철 역사를 역사 요소와 토지 요소로 구분하여 이에 관련된 여러 변수를 선택하여 군집분석을 수행하였다. 이는 단일 유형의 데이터를 사용한 기존 연구의 한계를 개선하여 지하철 관련 연구의 확장에 기여하였다. 둘째, 기존의 유형화 관련 연구는 주로 전자상거래, 도시정책 개발 등의 분야에서

널리 사용되었으나 대중교통 분야에 적용한 연구는 부족한 실정이었다. 현재 지하철 지하철 노선 수는 꾸준히 증가하고 이를 이용하는 승객도 계속 늘어나고 있다. 따라서 대중교통의 지속 가능한 발전을 위해서는 각 노선의 특성을 바탕으로 유형을 분류하고 유형별 특성에 맞는 정책을 수립할 필요성이 있다. 본 연구는 이러한 지하철 유형화를 위해 역사 특성을 나타내는 여러 변수를 선택하여 지하철 역사를 3개의 군집으로 분류하고 각 군집의 특성을 파악하였다. 이는 대중교통 분야에서 시도하지 않은 특성 유형화를 서울 지하철 역사에 적용함으로써 관련 연구의 확장에 기여하였다.

본 연구의 실무적 시사점은 다음과 같다. 첫째, 산업화 및 도시화가 빠르게 진행됨에 따라 수도권을 중심으로 시민들의 편의를 위한 대중교통 체계가 꾸준히 보완되고 있다. 다시 말해, 기존의 획일적인 대중교통 관리방식에서 더 나아가 체계적이고 차별화된 대중교통 전략에 대한 필요성이 꾸준히 제기되고 있다. 이와 같은 측면에서 본 연구는 수도권 지하철을 역사 특성에 따라 유형 구분을 시도하였으며, 실무자들이 향후 지하철 관련 정책을 개발할 때 본 연구에서 도출한 유형별 특성을 참고자료로 활용할 수 있을 것으로 기대한다. 둘째, 지하철 역사는 광고, 프로모션 등을 통해 수익 창출을 도모하고 있다. 현재 지하철 역사 광고는 유동 인구, 환승역 등 기본 정보만을 고려하기 때문에 특정 역사 혹은 이용 승객 그룹에 적합한 광고를 서비스하기 어려운 측면이 존재한다. 따라서 지하철 광고 담당 실무자는 본 연구의 결과를 바탕으로 지하철 역사 유형에 따른 맞춤형 광고를 게재하면 광고 효과가 상승하는 것을 기대할 수 있다.

본 연구는 대표적인 대중교통인 지하철을 유형화하고, 유형별 특성을 바탕으로 대중교통의 지속 가능한 발전을 위한 이론적 및 실무적 시사점을 도출하였으나 여전히 다음과 같은 한계점을 가지고 있다. 첫째, 본 연구는 지하철 역사 특성을 나타내는 여러 정량적인 변수를 선정하고 이를 군집분석을 통해 유형 특성을 구분하였다. 하지만, 결과 해석을 위해 제한적인 여러 사례를 참고하여 지하철 역사 특성과 문제점을 도출하였기 때문에 결과를 일반화할 때 여러 한계점이 존재한다. 향후 연구에서는 대표적인 대중교통인 지하철과 관련된 많은 사례를 참조하여 지하철 이용 패턴 변화와 문제점을 정교하게 분석하고 이를 통해 승객 맞춤형 정책이나 서비스가 마련되어야 한다. 둘째, 본 연구는 한정된 공공 데이터를 사용하여 지하철 역사의 특성을 분류하였기 때문에 분류 결과를 일반화하기에는 한계가 존재한다. 특히, 지하철 역사를 이용하는 승객의 특성을 설명할 수 있는 나이, 연령대 등 다양한 변수들이 존재하지만, 개인정보 등 문제로 인해 데이터 수집이 어려운 한계가 존재한다. 향후 연구에서는 이러한 데이터 수집 한계가 해결되면 지하철 역사의 특성을 더욱 효과적으로 분류할 수 있을 것으로 기대한다. 셋째, 본 연구는 지하철 역사 유형 특성을 분류하기 위해 다양한 연구에서 널리 사용된 데이터 마이닝 기반 군집분석 기법을 적용하였다. 최근 많은 연구에서 딥러닝을 적용한 군집분석 기법이 제안되고 있으며, 향후 연구에서는 이와 같은 딥러닝 기반 군집분석 기법을 시도한다면 유형을 더욱 정교하게 분류할 수 있을 것으로 기대한다.

참고문헌

권순재 · 김성현 · 탁온식 · 정현희(2017). K-Means Clustering 알고리즘과 헤도닉 모형을 활용한 서울시 연립· 다세대 군집 분류 방법에 관한 연구. 『지능정보연구』, 23(3), 95-118.

김용민 · 김환배 · 정혜영 · 이명훈(2017). 지하철2 호선 역세권 별 유출입특성과 역세권 토지이용에 관한 연구. 『한국지역개발학회지』, 29(3), 157-179.

김진수(2016). 빅데이터 분석을 이용한 지하철 혼잡도 예측 및 추천시스템. 『Journal of Digital Convergence』, 14(11), 289-295.

김찬주 · 김영욱(2007). 지하철 역사 공간에서 승객의 유동 패턴에 관한 연구: 지하철2 호선 강남역을 중심으로. 『대한건축학회 논문집-계획계』, 23(11), 71-78.

문서현(2017). 철도 역내 상업시설의 이용 활성화를 위한 개선방안 모색: 일본의 역내 상업시설 'ecute'에 관한 고찰을 중심으로. 『한국실내디자인학회 논문집』, 26(3), 101-112.

민미경(2018). 기계학습 클러스터링을 이용한 승하차 패턴에 따른 서울시 지하철역 분류. 『한국인터넷방송통신학회 논문지』, 18(4), 13-18.

박주석(2018). 빅데이터, 오픈데이터, 마이데이터의 비교 연구. 『한국빅데이터학회지』, 3(1), 41-46.

성진홍(2018). 『기계학습을 이용한 서울 지하철 승하차 인원예측』(석사학위논문, 한양대학교).

성현곤 · 노정현 · 김태현 · 박지형(2006). 고밀도시에서의 토지이용이 통행패턴에 미치는 영향: 서울시 역세권을 중심으로. 『대한국토·도시계획학회지국토계획』, 41(4), 59-75.

손동욱 · 김진(2010). 서울시 역세권의 도시공간특성과 대중교통 이용률 간의 연관성 분석. 『한국도시설계학회지 도시설계』, 11(1), 33-44.

송민경 · 장훈(2010). 군집분석을 이용한 수도권 도시의 유형화에 관한 연구. 『대한공간정보학회지』, 18(1), 83-88.

송치영 · 서상혁 · 곽승현 · 이석환 · 민병찬(2018). 지하철 광고의 부정적 정서자극과 청각자극의 동시자극이 자율신경계에 미치는 영향 연구. 『예술인문사회 융합 멀티미디어 논문지』, 8(8), 99-106.

신임호(2012). 『서울시 지하철 통행패턴을 통한 연령계층별 활동중심지 분석연구』(박사학위논문, 한양대학교).

엄태휘 · 고선영 · 정남호(2021). COVID-19 전후 제주도 내비게이션 데이터를 이용한 주민 및 관광객의 이동밀도 및 목적지 군집분석 비교. 『인터넷전자상거래연구』, 21(2), 35-51.

여인권(2011). 우리나라 기상자료에 대한 군집분석. 『한국데이터정보과학회지』, 22(5), 941-949.

이근영 · 정성봉 · 노주희(2014). 도심 지하철 역사 활용 다양화 방안 연구. 『한국철도학회 학술발표대회논문집』(pp. 994-999).

이다예 · 이희연(2016). 지역맞춤형 정책 수립을 위한 수도권 근교농촌의 유형화 및 특성 분석. 『지역연구』, 32(2), 15-29.

이상준 · 신성일(2020). 교통카드 자료를 활용한 지하철 혼잡도 개선 연구. 『한국IT 서

비스학회지』, 19(2), 125-138.

이성희(2022.05.11). 지하철 타고 버스 타고 123㎞를?…서울시민, 하루930만건 대중교통 이용. 『경향신문』, Retrieved from https://www.khan.co.kr/national/national-general/article/202205110600001

이종민 · 한광석(2007). 지하철광고 제도의 문제점 및 개선방안. 『OOH 광고학연구』, 4(1), 5-23.

이준호 · 박광호(2012). 군집분석을 통한 중소기업 온라인 마케팅 지원 수혜기업의 세분화 전략에 관한 연구: 창업기업 홍보마케팅 지원사업(HIT500) 참여기업 중심으로. 『e-비즈니스연구』, 13(4), 169-194.

이창효 · 이승일(2010). 서울시1 인 가구의 밀집지역 분석과 주거환경 평가. 『서울도시연구』, 11(2), 69-84.

임상빈 · 김병남(2021). 『서울시 오피스텔 및 상가 건축물 시가표준액 산정체계 개선방안』. 서울: 한국지방세연구원

장재민 · 이경철 · 김태형(2016). 지하철 역사 내 임대시설 적정 면적 및 임대료 산정에 영향을 미치는 변수에 관한 연구: 서울 지하철5 호선, 6 호선을 사례로. 『한국철도학회논문집』, 19(3), 380-387.

전병진 · 김희웅(2017). 공공 빅데이터 개방 및 활용 활성화 방안에 대한 연구. 『정보화정책』, 24(3), 27-41.

조수진 · 김보경 · 김나현 · 송종우(2019). 데이터마이닝 기법을 이용한 서울시 지하철역 승차인원 예측. 『응용통계연구』, 32(1), 111-128.

최봉 · 윤종진(2018). 『서울시 공공빅데이터 활성화방안』. 서울: 서울연구원

한상욱 · 강희용 · 이명훈(2015). 교통카드 데이터를 활용한 주요 역세권별 대중교통 이용 통근통행자의 주거지 분포: 수도권을 대상으로. 『대한국토·도시계획학회지 국토계획』, 50(4), 103-117.

황보현우(2018.09.10). [기고]빅데이터 기반 지하철 쾌적 경로 서비스 제공해야. 『전자신문』, Retrieved from https://www.etnews.com/20180910000169

Ahmad, A., & Khan, S. S. (2019). Survey of state-of-the-art mixed data clustering algorithms. *IEEE Access, 7*, 31883-31902.

Bharati, S., Podder, P., & Mondal, M. R. H. (2020, June). Diagnosis of polycystic ovary syndrome using machine learning algorithms. *In 2020 IEEE Region 10 Symposium (TENSYMP)*. (pp. 1486-1489). Dhaka, Bangladesh.

Ezugwu, A. E., Ikotun, A. M., Oyelade, O. O., Abualigah, L., Agushaka, J. O., Eke, C. I., & Akinyelu, A. A. (2022). A comprehensive survey of clustering algorithms: State-of-the-art machine learning applications, taxonomy, challenges, and future research prospects. *Engineering Applications of Artificial Intelligence, 110*, 104743.

Mathivanan, N. M. N., Ghani, N. A. M., & Janor, R. M. (2019). Analysis of k-means clustering algorithm: A case study using large scale e-commerce products. *In 2019 IEEE Conference on Big Data and Analytics (ICBDA)* (pp.

1-4). Pulau Pinang, Malaysia.

Murtagh, F., & Contreras, P. (2012). Algorithms for hierarchical clustering: an overview. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 2*(1), 86-97.

Roux, M. (2018). A comparative study of divisive and agglomerative hierarchical clustering algorithms. *Journal of Classification, 35*(2), 345-366.

Shukla, S., & Naganna, S. (2014). A review on K-means data clustering approach. *International Journal of Information and Computation Technology, 4*(17), 1847-1860.

Syakur, M., Khotimah, B., Rochman, E., & Satoto, B. D. (2018). Integration k-means clustering method and elbow method for identification of the best customer profile cluster. *IOP Conference Series: Materials Science and Engineering, 336*(1), 012017.

Xu, D., & Tian, Y. (2015). A comprehensive survey of clustering algorithms. *Annals of Data Science, 2*(2), 165-193.

Xu, R., & Wunsch, D. (2005). Survey of clustering algorithms. *IEEE Transactions on Neural Networks, 16*(3), 645-678.

Zarikas, V., Poulopoulos, S. G., Gareiou, Z., & Zervas, E. (2020). Clustering analysis of countries using the COVID-19 cases dataset. *Data in Brief, 31*, 105787.